


Busca Informada

Inteligência Artificial
PCS3438

Escola Politécnica da USP
Engenharia de Computação
(PCS)

Busca Informada

- Usa conhecimento específico do problema na busca da solução
- Também chamadas de **Busca Heurística**
- Mais eficientes que busca não informada



Busca
Informada
(ou Busca
Heurística):
Ideia básica

3

Busca pela Melhor Escolha (BME)
(**Best-first search**)

- Seleciona para expansão o nó que tiver o mínimo custo estimado até a meta, segundo uma função de avaliação $f(n)$.
- Tipicamente $f(n)$ usa uma função heurística $h(n)$ que estima o custo da solução a partir de n .
- Na meta, $h(n) = 0$.

Greedy best-first search

*Busca
gulosa pela
melhor
escolha*

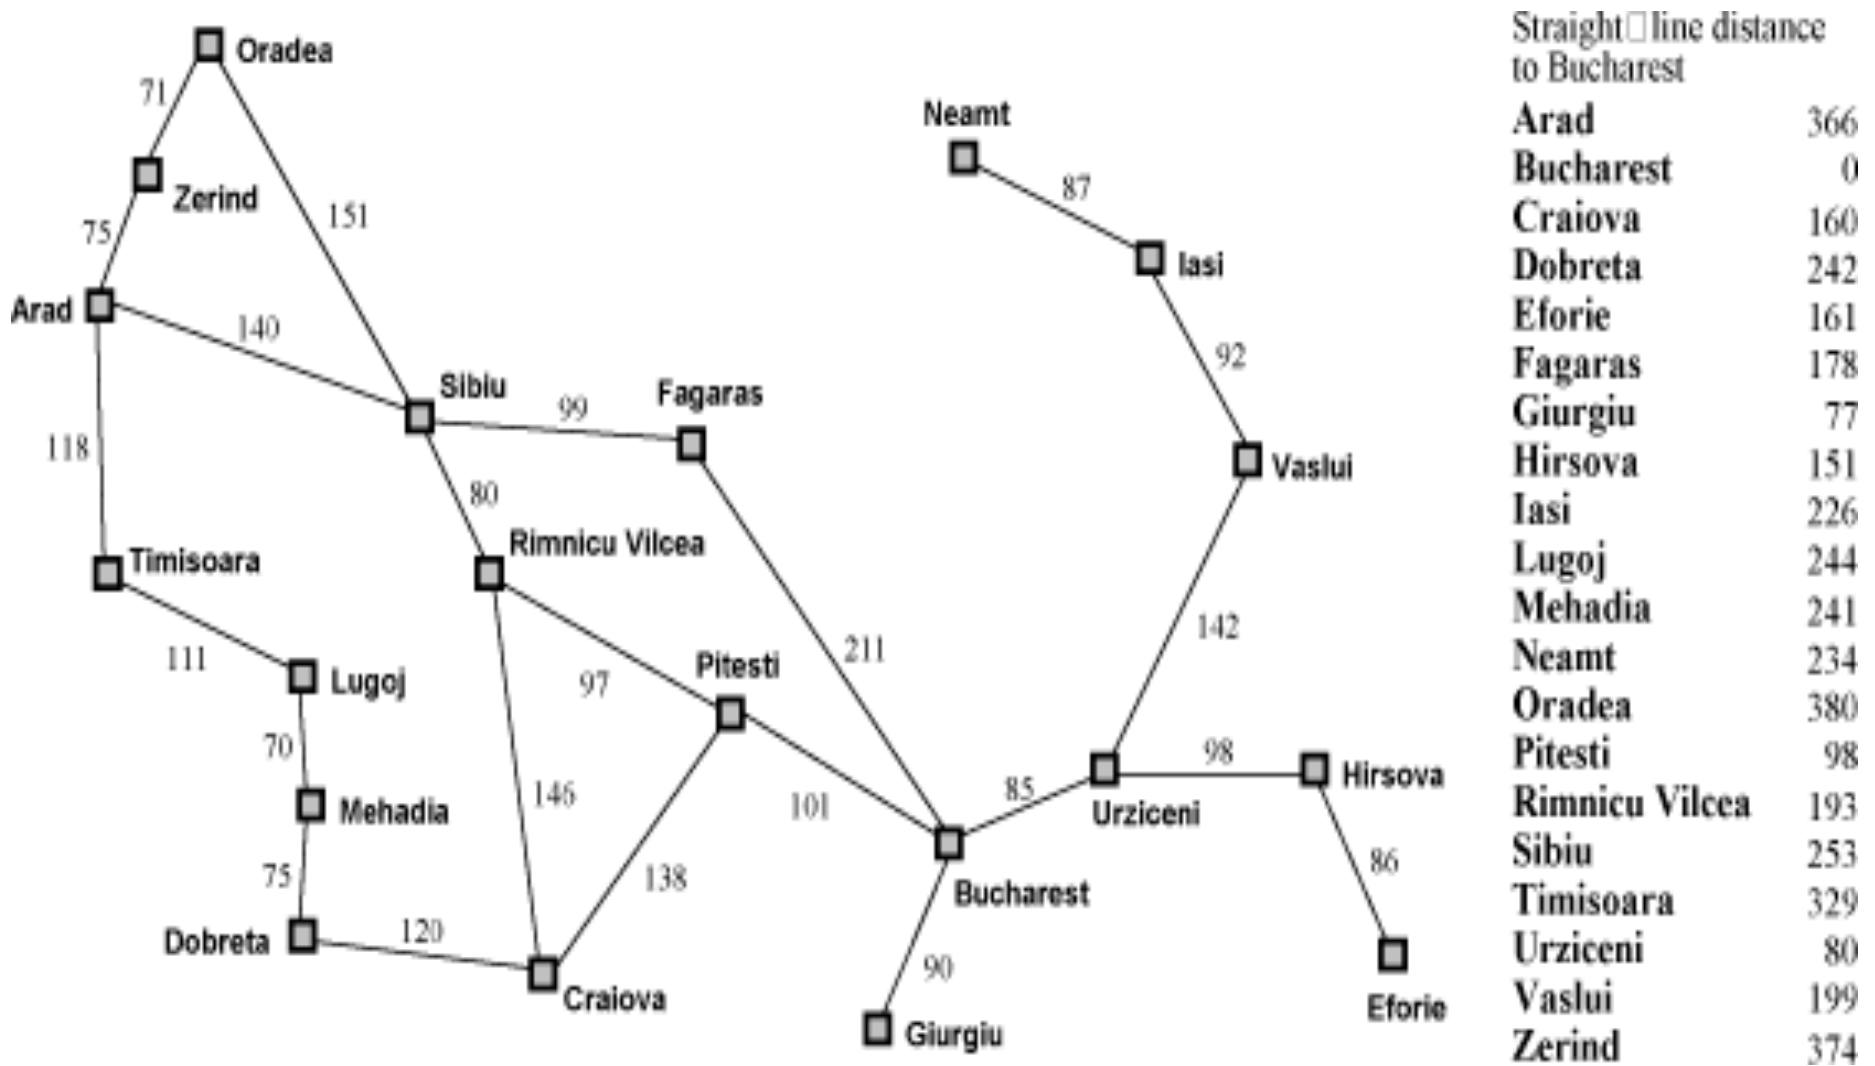


Avalia nós para expandir com base unicamente na função heurística:

$$f(n) = h(n)$$




Semelhante à busca em profundidade com retrocesso (*backtracking*)

Exemplo: ir de Arad a Bucharest usando Greedy BME



Usando Greedy BME

Arad ●
h=366



Desempenho da Greedy BME

7

- **Não é completa**
 - pode entrar em ciclos e não encontrar a solução se não detectar estados repetidos (idem BP)
 - pode se perder em um caminho infinito e nunca retroceder para tentar outras opções (idem BP)
- **Não é ótima**
 - No ex: encontrou caminho (Arad, Sibiu, Fagaras, Bucharest) que é 32km maior que (Arad, Sibiu, Rimnicu Vilcea, Pitesti, Bucharest)
- **Complexidade de tempo e espaço no pior caso: $O(bm)$**
 - m é a máxima profundidade do espaço de busca
- **Dependendo do problema e da qualidade da heurística a complexidade pode ser substancialmente reduzida.**



BME mais “famoso”:

A*

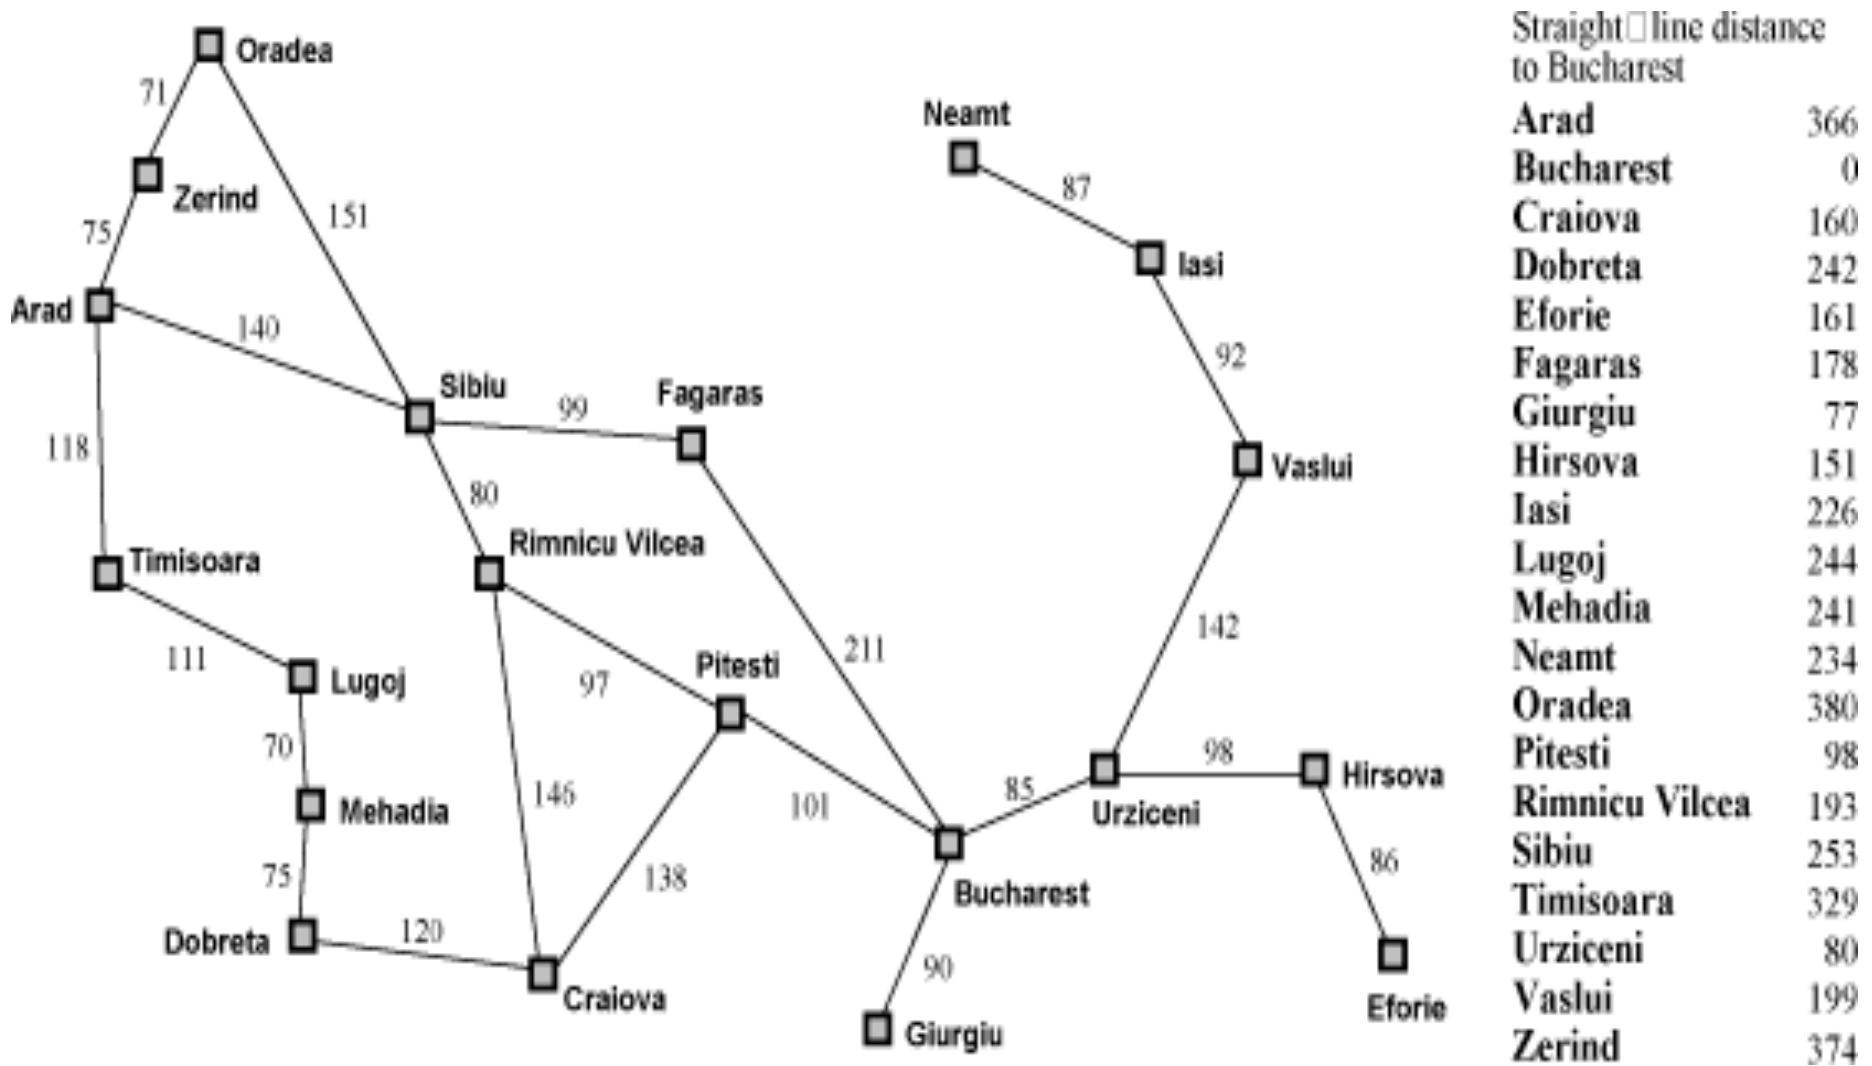


- Função de avaliação:

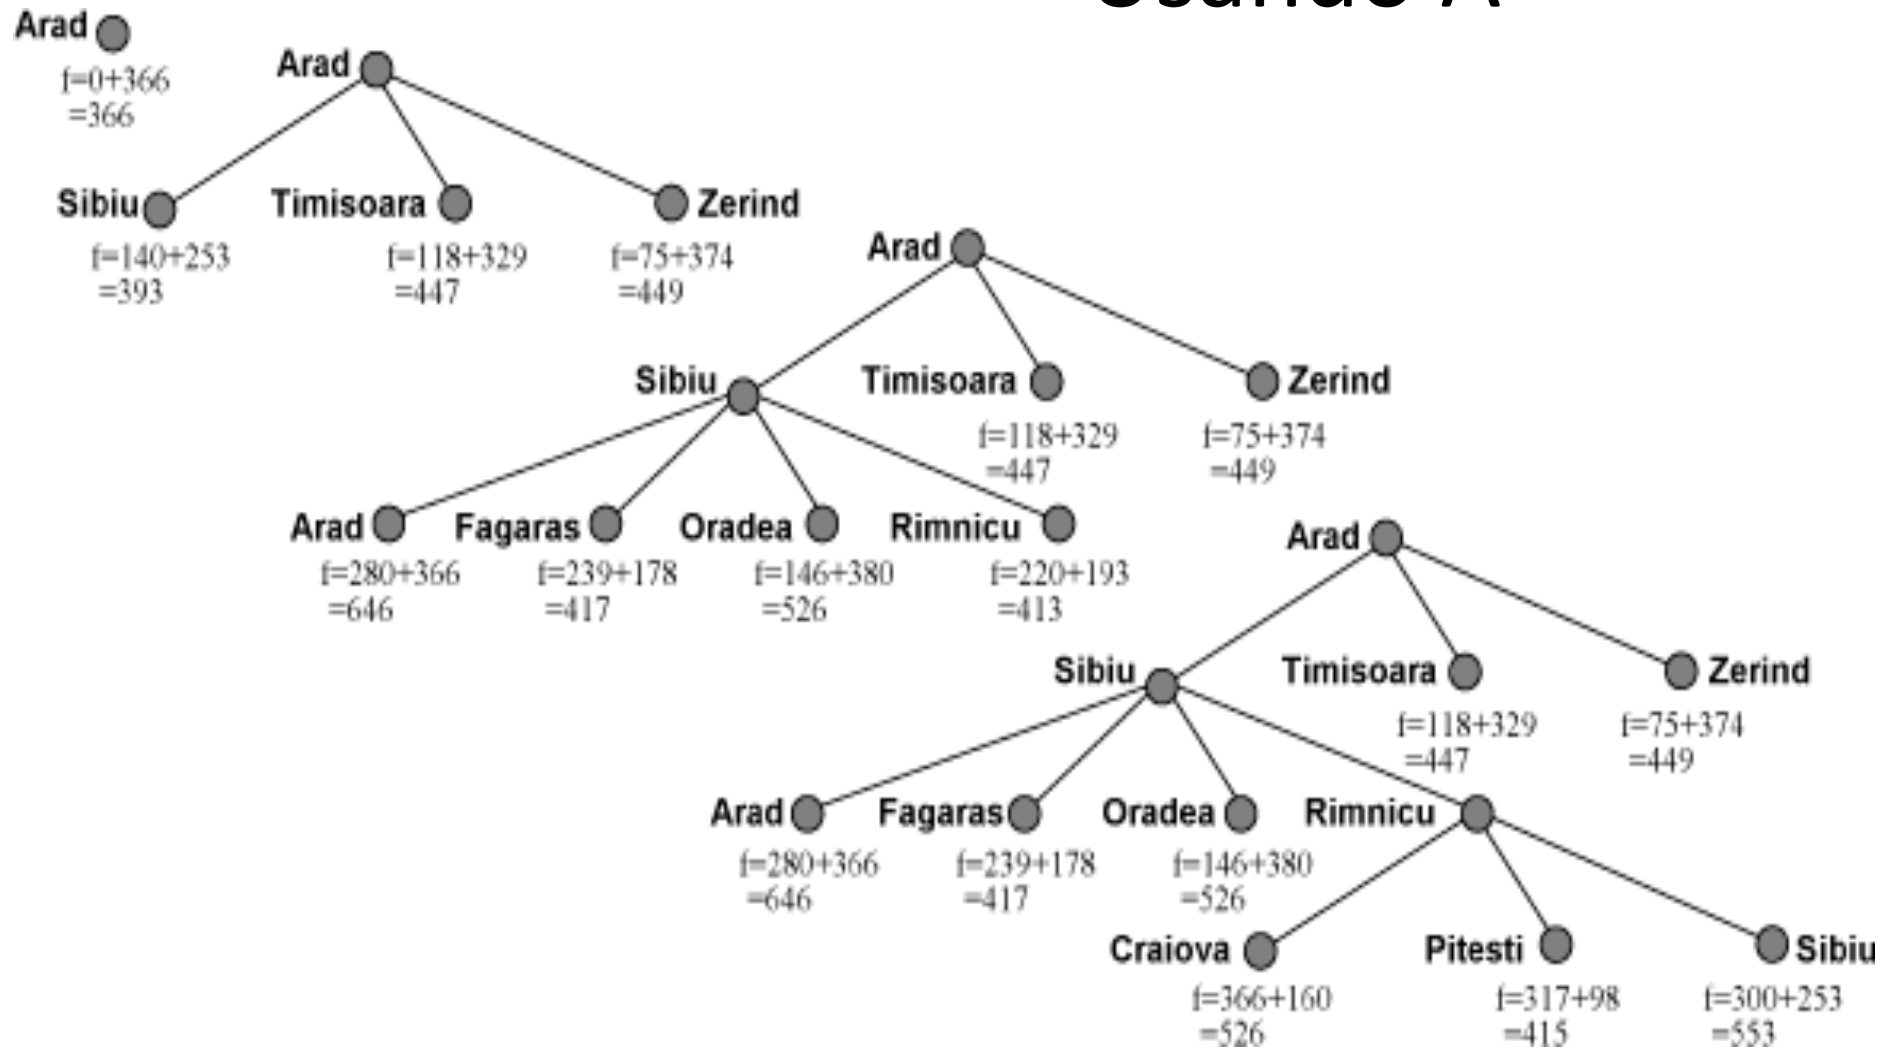
$$f(n) = g(n) + h(n)$$

- $g(n)$ = distância (custo) **real** do nó inicial ao nó n
 - $h(n)$ = distância (custo) **estimada** de n ao nó final
 - $f(n)$ **estima** o custo da melhor solução que passa por n
-
- A* expande o nó de menor valor de f na fronteira do espaço de estados
 - idêntico à Busca de Custo Uniforme, só que usa $g+h$ em vez de g


Exemplo: ir de Arad a Bucharest usando A*



Usando A*



Desempenho do A^*



11

- **A^* é completo e ótimo se $h(n)$ for admissível e consistente**
 - **h admissível:** nunca superestima o custo de atingir a meta **(1)**
 - **h consistente (ou monotônica) (2)**
$$h(n) \leq c(n,a,m) + h(m), \quad \forall n, m$$

ou $(h(n) - h(m)) \leq c(n,a,m)$
- m é sucessor de n , gerado pela ação a ; $c(n,a,m)$ é o custo de sair de n e atingir m usando a .
- Se h é consistente, os valores de $f(n)$ através de qualquer caminho são crescentes.

Busca A*: comentários

12

- A* é otimamente eficiente
 - nenhum outro algoritmo ótimo garante expandir menos nós que A*.
- Geralmente há crescimento exponencial do número de nós com o comprimento da solução (complexidade temporal).
- Mas o maior problema é a complexidade espacial: A* armazena todos os nós gerados!
- Função de avaliação: compromisso (conflito) entre:
 - tempo gasto na seleção de nó (computar h)
 - redução do espaço de busca

Busca Heurística com Memória Limitada

IDA* (Iterative Deepening A*)

- Similar ao BAI, porém seu limite é dado pela função de avaliação (f), e não pela profundidade (d).
- usa menos memória que A*

SMA* (Simplified Memory-Bounded A*)

- O número de nós guardados em memória é fixado previamente

HEURÍSTICAS – COMO DEFINIR?

Inventando Funções Heurísticas

- Como escolher uma boa função heurística h ?
 - h depende de cada problema particular.
 - h deve ser *admissível*: não superestimar o custo real da solução
- Exemplo: jogo dos 8 números
 - um número pode mover-se de A para B se A é adjacente a B e B está vazio
 - busca exaustiva (ou cega ou não informada):
 - solução média em 22 passos
 - fator de ramificação médio: 3
 - Assim $\approx 3^{22}$ estados possíveis

4	5	8
	1	6
7	2	3

Heurísticas para o jogo 8 números

- $h1$ = no. de elementos fora do lugar
- $h2$ = soma das distâncias de cada número à posição final (distância de Manhattan)

5	4	
6	1	8
7	3	2

Start State

1	2	3
8		4
7	6	5

Goal State

$$h1 = 7$$

$$h2 = 2+3+3+2+4+2+0+2 = 18$$

Qualidade da função heurística

- Mede-se empiricamente a partir do conjunto de valores experimentais de **N** e **d**.
- Dada através do fator de expansão efetivo b^*
 - b^* é o fator de expansão de uma árvore uniforme com $N+1$ nós e nível de profundidade d
 - $N+1 = 1 + b^* + (b^*)^2 + \dots + (b^*)^d$
 - N = total de nós gerados pelo A^* para um problema
 - d = profundidade da solução
 - Ex: $N = 52, d = 5 \rightarrow b^* = 1.92$
- Uma boa função heurística terá o b^* muito **próximo de 1**.

Escolhendo Funções Heurísticas

18

- Usar uma função heurística de valores mais altos, desde que seja admissível e que o tempo para computá-la não seja muito grande!
 - ex. h_2 melhor que h_1
- h_i **domina** $h_k \Rightarrow h_i(n) \geq h_k(n), \forall n$
 - ex. h_2 domina h_1 .
- Se várias h e nenhuma domina a outra, usa-se uma **heurística composta**:
 - $h(n) = \max (h_1(n), h_2(n), \dots, h_m(n))$

Como inventar funções heurísticas admissíveis?

- (1) Relaxar o problema
(versão simplificada)
- (2) Usar informação
estatística
- (3) Identificar atributos
relevantes do
problema e usar
aprendizagem

(1) Relaxando o problema

- Operadores relaxados:
 - 1. Uma peça pode se mover para lugares adjacentes, mesmo que ocupados
 - h_2 seria o custo da solução “correta” neste jogo
 - 2. Uma peça pode se mover para qualquer lugar vazio, mesmo que não adjacente
 - 3. Uma peça pode se mover para qualquer lugar
 - h_1 seria o custo da solução “correta” neste jogo

O custo da solução ótima de um problema relaxado é uma heurística admissível para o problema original!!!

(2) Usando informação estatística

- Funções heurísticas podem ser “melhoradas” com informação estatística:
 - executar a busca com um conjunto de treinamento (ex., 100 configurações diferentes do jogo), e computar os resultados.
 - se, em 90% dos casos, quando $h(n) = 14$, a distância real da solução é 18, então, quando o algoritmo encontrar 14 para o resultado da função, pode substituir esse valor por 18.
- Informação estatística expande menos nós, porém elimina admissibilidade:
 - em 10% dos casos do problema acima, $h(.)$ poderá superestimar o custo da solução!

(3) Aprendendo heurísticas por experiência

- Resolve o jogo diversas vezes e computa o custo da solução, relacionando a algum atributo do problema.
 - Ex1: atributo $x_1(n)$ = número de peças fora do lugar no início do jogo; para cada valor de atributo, determinar experimentalmente o custo médio da solução.
 - Ex: para $x_1(n)=5$, resolvo 100 vezes o problema e concluo que o custo médio da solução é 14 passos
 - Ex2: atributo $x_2(n)$ = número de pares de peças adjacentes que também são adjacentes na configuração de solução
- Uso $x_1(n)$ e/ou $x_2(n)$ para estimar $h(n)$:
 - $h(n) = c_1 \cdot x_1(n) + c_2 \cdot x_2(n)$, ajustando (aprendendo) c_1 e c_2 da melhor forma para os dados de custo da solução.

Bibliografia

- Busca cega e heurística:
 - Capítulo 3 do livro texto (Russel & Norvig, Inteligência Artificial, 3a. Edição)